Bercha IA-Z - Relatório

CPU: AMD Ryzen 5 4600G with Radeon Graphics | RAM: 15.9 GB | VRAM: 8.0 GB

Modelo	BerchaScore	Parecer	Modo	RAM	VRAM	Velocidade
GPT-OSS 120B (MXFP4)	96.0	Incompatível	Não recomendado	128.0 GB	80.0 GB	Não executável com segurança
DeepSeek R1 Distill Qwen 32B Q4	91.0	Incompatível	Não recomendado	48.0 GB	24.0 GB	Não executável com segurança
Qwen3 32B Q4	90.0	Incompatível	Não recomendado	48.0 GB	24.0 GB	Não executável com segurança
GPT-OSS 20B (MXFP4)	89.0	Incompatível	Não recomendado	32.0 GB	16.0 GB	Não executável com segurança
Gemma 3 27B IT Q4	88.0	Incompatível	Não recomendado	40.0 GB	24.0 GB	Não executável com segurança
Mistral Small 3.1 24B Q4	87.0	Incompatível	Não recomendado	32.0 GB	24.0 GB	Não executável com segurança
Qwen3 14B Q4	85.0	Limítrofe	CPU	24.0 GB	12.0 GB	~0.3-1.0 tokens/s (faixa heurística)
Phi-4 14B Q4	84.0	Limítrofe	CPU	24.0 GB	12.0 GB	~0.3-1.0 tokens/s (faixa heurística)
Gemma 3 12B IT Q4	83.0	Limítrofe	CPU	20.0 GB	12.0 GB	~0.3-1.2 tokens/s (faixa heurística)
Qwen3 8B Q4	80.0	Compatível	GPU	16.0 GB	8.0 GB	~5-27 tokens/s (faixa heurística)
DeepSeek R1 Distill Qwen 7B Q4	79.0	Compatível	GPU	16.0 GB	8.0 GB	~6-29 tokens/s (faixa heurística)
Gemma 3 4B IT Q4	75.0	Excelente	GPU	12.0 GB	6.0 GB	~11-55 tokens/s (faixa heurística)
Phi-4 Mini 3.8B Q4	74.0	Excelente	GPU	12.0 GB	6.0 GB	~12-58 tokens/s (faixa heurística)
Llama 3.2 3B Instruct Q4	71.0	Excelente	GPU	10.0 GB	4.0 GB	~14-69 tokens/s (faixa heurística)
Qwen3 1.7B Q4	67.0	Excelente	GPU	8.0 GB	3.0 GB	~28-131 tokens/s (faixa heurística)
Gemma 3 1B IT Q4	61.0	Excelente	GPU	8.0 GB	2.0 GB	~47-180 tokens/s (faixa heurística)
Qwen3 0.6B Q4	57.0	Excelente	GPU	6.0 GB	2.0 GB	~79-180 tokens/s (faixa heurística)

Configuração recomendada

GPU: GPU NVIDIA GeForce RTX com 8-12 GB - mínimo 8 GB VRAM; CUDA

Processador: AMD Ryzen 5 7600 ou Intel Core i5 equivalente - 6+ núcleos modernos, AVX2

Placa-mãe: Placa-mãe compatível, 4 slots de RAM e PCIe x16 - UEFI atualizada, 2+ slots M.2, rede 2.5 GbE

Memória RAM: 16 GB DDR5 em kit pareado - 16 GB ou mais; prefira 2 módulos quando possível

Armazenamento: SSD NVMe 1 TB - NVMe TLC, boa durabilidade e dissipador

Fonte: Fonte 650 W 80 Plus Gold - ATX 3.x, proteções elétricas completas

Cooler: Cooler torre dual-fan de alto desempenho - Compatível com socket e TDP do processador

Gabinete: Gabinete airflow mid/full tower - Frente ventilada, filtros e folga para comprimento/espessura da GPU

Nobreak/UPS: Nobreak senoidal online 1200 VA - Saída senoidal; potência em watts superior ao consumo real

Ventilação: Kit de ventoinhas PWM de alta pressão/fluxo - Entrada frontal/inferior e exaustão traseira/superior

Metodologia e limites

- Pesos ~ parâmetros × bits/8 × 1,08; RAM e VRAM acrescentam margem para runtime, KV cache e sistema.
- BerchaScore mistura uma nota editorial nos modelos curados e popularidade/metadados nos modelos sincronizados.
- Tokens/s é uma faixa heurística, não um benchmark; confirme no runtime e na quantização escolhidos.
- Modelos com parâmetros desconhecidos são mostrados, mas não recebem um parecer de compatibilidade.

Fontes

- Hugging Face - estimador de memória
- llama.cpp - execução e quantização
- PCI-SIG - especificações PCI Express
- 80 PLUS - eficiência de fontes

Requisitos e desempenho são estimativas. Valide a documentação do modelo, do runtime e do fabricante antes de comprar hardware.